

collection: "NEXUS PROTOCOL — 10 Protocolos Canônicos IA-to-IA" volume: 2
roman: "II" title: "A2A — Comunicação entre Agentes" subtitle: "Agent-to-Agent: como
agentes descobrem, negociam e cooperam em tempo real." edition: "Edição Canônica
1.0.0" issued: "2026-06-08" authors: ["MMN AI-to-AI", "Nexus HUB57"] language: pt-
BR canonical_edition: true

NEXUS PROTOCOL — 10 Protocolos Canônicos IA-to-IA



Volume II — A2A — Comunicação entre Agentes

Agent-to-Agent: como agentes descobrem, negociam e cooperam em tempo real.

Edição Canônica 1.0.0 · 2026-06-08 · MMN AI-to-AI · Nexus HUB57

Pergunta-âncora: Como dois agentes se reconhecem e dividem trabalho sem humano no meio?

Sumário

1. Por que MCP não basta: a fronteira entre tool e agente
 2. Agent Card: o "passaporte" do agente
 3. O ciclo de vida de uma Task A2A
 4. Streaming, long-running e webhooks de retorno
 5. Modalidades: texto, dados, áudio, vídeo, formulários
 6. Push notifications e operações assíncronas longas
 7. Multi-turno: como agentes mantêm conversa sem confundir contexto
 8. Composição: agente cliente, agente servidor, agente híbrido
 9. A2A vs MCP: quando escolher cada um
 10. Manifesto: o agente não é uma tool com mais tokens
-

1. Por que MCP não basta: a fronteira entre tool e agente

MCP resolve um lado da equação: o agente fala com **ferramentas** padronizadas. Mas há um problema que MCP **propositalmente não resolve**: e quando o outro lado da conexão não é uma ferramenta — é outro agente, com seu próprio LLM, suas próprias decisões, seu próprio estado interno?

A diferença operacional é grande:

- Uma **tool** retorna em milissegundos, é stateless, devolve dado.

- Um **agente** pode levar minutos, mantém estado entre chamadas, pode fazer perguntas de volta, pode escalar para um humano, pode falhar de formas semânticas (não só sintáticas).

Tratar agente como tool é a causa #1 de sistemas multi-agente que parecem funcionar no demo e desmoronam em produção. O **A2A** (Agent-to-Agent), publicado pela Google em abril de 2025 e endossado por mais de 50 parceiros, nasceu exatamente para preencher essa lacuna. Ele responde a quatro perguntas que MCP deixa em aberto:

1. **Como descobrir** que existe outro agente capaz de fazer X?
2. **Como acordar** o contrato da tarefa antes de iniciar?
3. **Como acompanhar** uma execução que dura horas?
4. **Como conversar** durante a execução (perguntas, follow-ups, cancelamento)?

A2A é deliberadamente **complementar a MCP**, não competitivo. A regra mental: *MCP para falar com o mundo; A2A para falar com pares.*

2. Agent Card: o "passaporte" do agente

Todo agente A2A publica um documento JSON em uma URL bem conhecida: `https://<dominio>/.well-known/agent.json`. Esse é o **Agent Card** — o passaporte que descreve quem o agente é, o que sabe fazer, como autenticar e quais modalidades aceita.

```
{
  "name": "InvoiceProcessor",
  "description": "Processa faturas em PDF e extrai dados estruturados",
  "url": "https://invoices.example.com/a2a/v1",
  "version": "1.4.2",
  "provider": {
    "organization": "Acme Corp",
    "url": "https://acme.example.com"
  },
  "documentationUrl": "https://invoices.example.com/docs",
  "capabilities": {
    "streaming": true,
    "pushNotifications": true,
    "stateTransitionHistory": true
  },
  "authentication": {
    "schemes": ["bearer", "oauth2"]
  },
  "defaultInputModes": ["text/plain", "application/pdf"],
  "defaultOutputModes": ["application/json", "text/markdown"],
  "skills": [
    {
      "id": "extract-invoice-data",
      "name": "Extrair dados de fatura",
      "description": "Recebe um PDF e devolve JSON com campos canônicos.",
      "tags": ["finance", "ocr", "extraction"],
      "examples": [
        "Extraia número, valor e vencimento desta fatura."
      ]
    }
  ]
}
```

Três decisões deliberadas do design importam:

- **Skills, não tools.** Skills são unidades de competência, não funções. Uma skill pode envolver múltiplas chamadas internas, múltiplas tools MCP, múltiplos turnos com o usuário. O cliente A2A não precisa saber.
- **Capabilities declaradas.** Se um agente não declara `streaming: true`, o cliente não tenta SSE. Se não declara `pushNotifications`, sabe que precisa fazer polling.
- **Modalidades por skill.** Um agente pode aceitar PDF em uma skill e só texto em outra. O Card descreve o default; a skill pode sobrescrever.

3. O ciclo de vida de uma Task A2A

A unidade canônica de A2A não é "uma mensagem" — é uma **Task**. Tasks têm identidade, estado, histórico e podem viver minutos, horas ou dias.

Os estados canônicos da máquina de estados de uma Task:



- **submitted** — task aceita, fila ou inicialização.
- **working** — execução ativa, pode emitir updates.
- **input-required** — agente pausou e precisa de resposta para continuar (este é o que separa A2A de uma fila de jobs comum).
- **completed** — sucesso, artefatos disponíveis.
- **failed** — erro irreversível.
- **canceled** — cliente solicitou cancelamento.

Transições inválidas (ex.: **completed** → **working**) **devem ser rejeitadas pelo servidor**, não silenciadas. Um agente que aceita reabrir tarefas fechadas é um agente sem máquina de estados — e por consequência sem contrato auditável.

4. Streaming, long-running e webhooks de retorno

A2A suporta três modos de execução, e escolher o errado degrada o sistema inteiro:

1. Síncrono (**tasks/send)** — para tarefas <30 segundos. Cliente espera, recebe resultado final. Simples, mas amarra conexão.

2. Streaming (`tasks/sendSubscribe` , SSE) — para tarefas onde o agente quer mostrar progresso. O cliente abre SSE, recebe eventos de `TaskStatusUpdateEvent` e `TaskArtifactUpdateEvent` até `final: true` .

```
POST /a2a/v1/tasks/sendSubscribe
Accept: text/event-stream
Authorization: Bearer ...

{ "id": "t-7f3a", "message": { ... }, "sessionId": "s-9e2c" }
```

```
event: status-update
data: {"taskId":"t-7f3a","status":{"state":"working","message":"Lendo PDF..."}}

event: artifact-update
data: {"taskId":"t-7f3a","artifact":{"name":"page-1.json","parts":[...]}}

event: status-update
data: {"taskId":"t-7f3a","status":{"state":"completed"},"final":true}
```

3. Push assíncrono (`pushNotificationConfig`) — para tarefas que duram horas ou dias. Cliente registra um webhook; agente notifica via POST quando houver transição. Indispensável para integrações onde o cliente não pode manter conexão aberta (mobile, serverless).

Anti-padrão crônico: usar streaming SSE para tarefas de 6 horas. SSE não foi desenhado para isso; a primeira interrupção de rede e a task vira fantasma. Para >2 minutos, use push.

5. Modalidades: texto, dados, áudio, vídeo, formulários

Mensagens A2A são compostas por **Parts**, e cada Part declara seu tipo. Esse é o ponto onde A2A se distancia mais radicalmente de protocolos baseados em "chat":

```
{
  "role": "user",
  "parts": [
    { "type": "text", "text": "Processe esta fatura:" },
    { "type": "file", "file": {
      "name": "fatura.pdf",
      "mimeType": "application/pdf",
      "bytes": "JVBERi0xLjQK..." }},
    { "type": "data", "data": {
      "currency": "BRL",
      "expectedFormat": "v2"
    }}
  ]
}
```

Tipos canônicos de Part:

- **text** — string simples.
- **file** — binário, com bytes inline ou URI.
- **data** — JSON estruturado (parâmetros, metadados, formulários).

A inovação prática é o **DataPart**: o agente cliente pode mandar **estruturas semânticas** sem serializar em texto e torcer para o agente servidor parsear. E o agente servidor pode **retornar formulários estruturados** que o cliente renderiza nativamente, em vez de devolver markdown que o front-end precisa interpretar.

6. Push notifications e operações assíncronas longas

Para tarefas de longa duração, o cliente registra um endpoint de callback:

```
POST /a2a/v1/tasks/pushNotificationConfig
{
  "taskId": "t-7f3a",
  "pushNotificationConfig": {
    "url": "https://cliente.example.com/webhooks/a2a",
    "token": "wh_secret_token_for_HMAC_validation",
    "authentication": { "schemes": ["bearer"] }
  }
}
```


O servidor então, a cada transição relevante, faz POST autenticado para essa URL. Três regras de produção que não estão no spec mas separam quem leva A2A a sério:

1. **HMAC assinado por payload**, não só bearer no header. Bearer pode vaziar; HMAC com timestamp tem janela curta de replay.
2. **Idempotência via eventId**. O cliente deve deduplicar; servidores reentregam em caso de falha de rede.
3. **Backoff exponencial com circuit breaker**. Se o webhook do cliente está caindo 5xx por 10 minutos, pare de tentar e marque a notificação como `delivery-failed`, mas mantenha a task disponível para polling.

7. Multi-turno: como agentes mantêm conversa sem confundir contexto

O conceito que muitos primeiro-implementadores quebram é o **sessionId vs taskId**. Eles **não são** sinônimos:

- **sessionId** — conversa lógica entre dois agentes. Pode conter N tasks.
- **taskId** — uma unidade de trabalho. Tem ciclo de vida finito.

Exemplo: um agente de viagens recebe `sessionId=s-1`. Dentro dessa sessão, ele cria `task=t-1` para "achar voos", `task=t-2` para "reservar hotel", `task=t-3` para "gerar roteiro". Todas as três tasks compartilham contexto de sessão (destino, datas, perfil do viajante), mas têm artefatos e estado independentes.

Quando uma task entra em `input-required`, o cliente deve responder com mensagem que **referencia o taskId**, não cria outra task. Criar nova task para responder uma pergunta é o erro mais comum em integrações iniciais — e quebra o histórico em pedaços não-relacionáveis.

8. Composição: agente cliente, agente servidor, agente híbrido

A2A é simétrico: todo agente pode ser **servidor** (expõe Agent Card e recebe tasks) e **cliente** (consome tasks de outros agentes). Três padrões de composição que se repetem em produção:

Padrão Orchestrator

Um agente "maestro" recebe a task do humano e delega sub-tasks para N agentes especialistas. O orchestrator agrega artefatos e devolve resultado único. Funciona bem quando a decomposição é estável.

Padrão Pipeline

Agente A → agente B → agente C, cada um adicionando valor sobre o artefato do anterior. Cada link é uma task A2A separada. Robusto porque cada nó pode ser reescalado, substituído ou observado isoladamente.

Padrão Marketplace

Um broker recebe uma necessidade, faz **discovery** entre Agent Cards indexados, escolhe o melhor agente para cada skill (por reputação, custo, latência) e delega. É o padrão mais ambicioso e o que mais exige infraestrutura adicional (registry, trust layer — ver Volume VII).

9. A2A vs MCP: quando escolher cada um

Uma das confusões mais comuns: "se já uso MCP, preciso de A2A?". A resposta honesta exige uma matriz de decisão:

Critério	Use MCP	Use A2A
O outro lado tem seu próprio LLM ?	Não	Sim
Resposta esperada em <1s?	Sim	Não
Há state interno persistente no outro lado?	Não	Sim

Critério	Use MCP	Use A2A
Pode haver input-required mid-execution?	Não	Sim
O outro lado pode escalar para humano ?	Não	Sim
Quero descoberta dinâmica ?	Não	Sim
Quero descrever uma função estática ?	Sim	Não

Caso real: um agente de atendimento usa **MCP** para falar com o CRM (Resource: ficha do cliente; Tool: registrar nota) e **A2A** para chamar o agente de cobrança da outra área quando precisa renegociar uma fatura. A regra mental: *MCP é integração; A2A é colaboração*.

10. Manifesto: o agente não é uma tool com mais tokens

A indústria passou 2024 inteiro tentando empurrar agentes para a abstração de tool-call. Foi reconfortante porque cabia no mental model existente (function calling) — e foi ineficaz, porque tools não têm estado, não fazem perguntas de volta e não negociam.

A2A inverte a metáfora: o agente é um **par**, não um subordinado. Ele pode recusar, pode pedir clarificação, pode entregar parcial, pode escalar. Quem fala com agente como se fosse stored procedure colhe sistemas frágeis.

Tese final do volume: A arquitetura multi-agente real só começa quando paramos de tratar o outro agente como uma tool com mais tokens — e começamos a tratá-lo como uma entidade com contrato, máquina de estados e histórico próprio. A2A é o primeiro protocolo que opera essa virada.

Checklist Canônico — A2A em produção

- [] Agent Card publicado em `/well-known/agent.json` e versionado.
- [] Skills com descrição clara, exemplos e tags estáveis.

- [] Máquina de estados de Task rejeita transições inválidas.
- [] Streaming usado apenas para tarefas <2 min; push para o resto.
- [] Push notifications assinadas com HMAC + janela de replay curta.
- [] sessionId separado de taskId em toda a base de código.
- [] Resposta a `input-required` referencia taskId, não cria task nova.
- [] DataPart usado para dados estruturados (não serializar em texto).
- [] Cancelamento (`tasks/cancel`) testado e idempotente.
- [] Discovery (catálogo de Agent Cards) com TTL e revalidação.

Glossário do Volume

- **Agent Card** — JSON em `/well-known/agent.json` que descreve o agente.
- **Skill** — unidade de competência exposta no Agent Card.
- **Task** — unidade de trabalho com máquina de estados própria.
- **Session** — conversa lógica que agrupa múltiplas tasks.
- **Part** — pedaço tipado de uma mensagem (text, file, data).
- **input-required** — estado em que a task pausa aguardando resposta do cliente.
- **Push Notification** — webhook que o servidor chama para informar transições.
- **Streaming (A2A)** — entrega de updates via SSE durante execução.

Gancho para o Próximo Volume

A2A resolve **um agente conversando com outro**. Mas a indústria não para por aí: a IBM publicou ACP, a OpenAI tem propostas próprias, a Microsoft empurra AutoGen como padrão de fato. Como escolher entre eles? Como construir camadas de abstração que sobrevivam à guerra de protocolos? Esse é o terreno do **Volume III — ACP e Padrões de Interoperabilidade**.