

A IA Perfeita — Volume II: Prompts, Algoritmos e Skills da Cognição Determinística

O grimório técnico da conversa com a máquina — engenharia de prompts, algoritmos de raciocínio e a biblioteca viva de Skills Agênticas MMN_IA

Coletânea MMN_IA · A IA Perfeita · Vol. 2 de 3

Por Nexus HUB57 · Ecossistema MMN_IA

MMN_IA • 2026

Sobre este ebook

Se o Volume I tratou de como construir o **corpo** da IA Perfeita — sua arquitetura, seus padrões, seu código —, este Volume II trata da **mente**: o modo como conversamos com ela, os algoritmos que ela executa internamente, e as Skills (habilidades reaproveitáveis) que transformam um agente genérico em um especialista de alto valor. Aqui você encontra uma engenharia de prompts que vai muito além de "truques" — vai à teoria dos padrões CRISPE, PEAR, ReAct, Reflexion, Tree-of-Thought e Graph-of-Thought; algoritmos de roteamento, seleção e composição que sustentam a IA Perfeita; e a biblioteca viva de Skills Agênticas MMN_IA — habilidades como "Pesquisador Crítico", "Negociador Determinístico", "Auditor Documental", "Analista Quantitativo" e tantas outras. Dezenove capítulos, prompts de referência prontos para colar, e a doutrina cognitiva completa do ecossistema.

Sumário

- 1. Manifesto da cognição determinística • 2. Anatomia de um prompt MMN_IA
- 3. Padrão CRISPE — Context · Role · Instruction · Steps · Personality · Expression • 4. Padrão PEAR — Persona · Expertise · Action · Result • 5. Padrão ReAct — Reason + Act, e por que ainda manda • 6. Padrão Reflexion — quando o agente revisa a si mesmo • 7. Padrão Tree-of-Thought (ToT) — explorar caminhos • 8. Padrão Graph-of-Thought (GoT) — raciocínio em rede • 9. Padrão Plan-and-Solve — separar planejamento de execução • 10. Algoritmos de roteamento: classificadores leves, embeddings, regras • 11. Algoritmos de

seleção de exemplos (few-shot dinâmico) • 12. Algoritmos de auto-consistência (self-consistency, majority voting) • 13. O conceito de Skill no MMN_IA • 14. Estrutura de uma Skill — anatomia, contrato e versionamento • 15. A biblioteca MMN_IA de Skills (catálogo v1.0) • 16. Composição de Skills — meta-skills e pipelines compostos • 17. Eval de Skills — como medir habilidade reaproveitável • 18. Anti-padrões em prompts e Skills • 19. Checklist & fechamento — o grimório do operador

1. MANIFESTO DA COGNIÇÃO DETERMINÍSTICA

Existe um senso comum, vagamente romântico, segundo o qual conversar com uma IA é uma arte mágica — "saber pedir do jeito certo". Esse romantismo é o inimigo número um da IA Perfeita. **Conversar com IA, no padrão MMN_IA, é engenharia.** É escolha de padrão, é estrutura de prompt, é decisão sobre algoritmo de raciocínio, é versionamento, é teste, é métrica. A magia, quando aparece, é consequência da disciplina — não o contrário.

Cognição determinística é o regime em que **dado o mesmo input estrutural, o output é previsível em distribuição**. Não há "criatividade aleatória" no espaço operacional sério: há temperatura controlada, sampling controlado, exemplos controlados, schema controlado.

Este ebook é o **grimório técnico** dessa engenharia. Cada padrão aqui é uma fórmula que funciona em produção, escrita para Operadores que cansaram de improvisar e querem cultivar uma prática reaproveitável. A promessa: ao final, você terá um vocabulário de mais de quinze padrões cognitivos, uma biblioteca de Skills, e métodos para combinar tudo isso em sistemas previsíveis.

A diferença entre um Operador iniciante e um Operador sênior não é "saber mais prompts". É **saber escolher o padrão certo para o problema certo**.

2. ANATOMIA DE UM PROMPT MMN_IA

2.1 As sete partes de um prompt completo



2.2 Por que essa ordem importa

Modelos de fronteira em 2026 leem prompts inteiros, mas **pesam mais o início e o fim**. Colocar contexto e objetivo cedo + formato e exemplos no fim maximiza adesão.

2.3 Tamanho ideal

System prompt MMN_IA típico: **300-1.200 tokens**. Acima disso, retornos decrescem fortemente. Se está crescendo, é sinal para decompor em chamadas menores.

2.4 Versionamento

Todo system prompt mora em arquivo `.md` versionado em Git, com cabeçalho:



Sem isso, prompt é folclore — não engenharia.

3. PADRÃO CRISPE — CONTEXT · ROLE · INSTRUCTION · STEPS · PERSONALITY · EXPRESSION

3.1 O padrão

Acrônimo popularizado por Matt Nigh (2023), refinado no ecossistema MMN_IA:

- **C**ontext — situação, dado, restrição
- **R**ole — papel que o modelo assume
- **I**nstruction — tarefa específica
- **S**teps — procedimento passo-a-passo
- **P**ersonality — tom e estilo
- **E**xpression — formato de saída

3.2 Template MMN_IA-CRISPE



3.3 Quando usar

Quando há **um papel claro** e **um procedimento conhecido**. Bom para: redação técnica, análise estruturada, atendimento padronizado, geração de relatórios.

3.4 Quando NÃO usar

Quando o problema é **exploratório** — para isso, ToT ou GoT. Quando exige uso de **ferramentas externas** — para isso, ReAct.

4. PADRÃO PEAR — PERSONA · EXPERTISE · ACTION · RESULT

4.1 O padrão

Padrão minimalista, ótimo para prompts curtos em produção de alta escala:

- **P**ersona — quem você é
- **E**xpertise — em que você é especialista
- **A**ction — o que você faz
- **R**esult — o que deve entregar

4.2 Exemplo



4.3 Por que funciona

Resolve em 4 linhas o que CRISPE faz em 12. Para tarefas de baixa complexidade em alta escala, **PEAR ganha em custo**.

5. PADRÃO REACT — REASON + ACT, E POR QUE AINDA MANDA

5.1 A ideia

Cada turno do modelo é dividido em:

Device Type	Percentage of Respondents
Smartphone	85%
Tablet	65%
Smartwatch	45%
Smart TV	35%
Smart Home Hub	25%
Smart Car	15%
Smart Thermostat	10%
Smart Light Bulbs	5%

5.2 Por que continua sendo o coração agêntico

Modelos modernos têm function calling estruturado, mas internamente continuam executando ReAct. Entender ReAct é entender **o que um agente faz**.

5.3 Template MMN_IA-ReAct

AI Agent	Percentage of Respondents
AI Agents to help REACT to data turnopoints	75%
AI Agents to help find data	30%
AI Agents to help find parameters	35%
AI Agents to help find data	5%
AI Agents to help find data	40%
AI Agents to help find data	0%
AI Agents to help find data	30%
AI Agents to help find data	25%
AI Agents to help find data	20%
AI Agents to help find data	15%
AI Agents to help find data	0%
AI Agents to help find data	50%

5.4 Cuidados

- Limite **max_iterations** (5-10 típico)
- Limite **token budget**
- Trate "ação inválida" como erro de schema
- Registre todo o trace para replay

6. PADRÃO REFLEXION — QUANDO O AGENTE REVISA A SI MESMO

6.1 A ideia (Shinn et al., 2023)

Após produzir uma resposta, o agente:



6.2 Diferença para Critic Pattern

- **Critic:** outro agente avalia.
- **Reflexion:** o **próprio** agente avalia. Mais barato, menos imparcial.

A IA Perfeita usa **os dois juntos** quando a tarefa é crítica.

6.3 Template MMN_IA-Reflexion



6.4 Quando paga o custo

Tarefas de redação, análise, raciocínio. Ganho médio observado: +10-25% em qualidade humana percebida.

7. PADRÃO TREE-OF-THOUGHT (ToT) — EXPLORAR CAMINHOS

7.1 A ideia (Yao et al., 2023)

Em vez de raciocinar linearmente, o agente **explora múltiplos caminhos** de raciocínio em paralelo:



7.2 Quando usar

Problemas com **múltiplas estratégias possíveis** e onde a estratégia certa não é óbvia: planejamento, design, escolha estratégica, problemas algorítmicos.

7.3 Custo

ToT pode multiplicar custo de tokens por 3-10x. Use com critério.

7.4 Template MMN_IA-ToT



8. PADRÃO GRAPH-OF-THOUGHT (GoT) — RACIOCÍNIO EM REDE

8.1 A ideia (Besta et al., 2023)

Generaliza ToT permitindo que **caminhos se cruzem, mesquem e dividam**, formando um grafo:



8.2 Quando vale a complexidade

Sistemas que precisam de **decomposição de problemas complexos** com **reuso de sub-soluções**: planejamento multi-agente, refatoração de código grande, análise de portfólio.

8.3 Implementação prática

Em 2026, GoT é mais frequentemente implementado como **orquestração explícita em código**, não como prompt único. O LLM resolve cada nó; o grafo é gerenciado externamente.

9. PADRÃO PLAN-AND-SOLVE — SEPARAR PLANEJAMENTO DE EXECUÇÃO

9.1 A ideia

Em vez de pedir solução direta, peça primeiro o **plano**:



9.2 Por que funciona

Modelos cometem menos erros quando **planejam antes de agir**. Inspirado em humanos, validado em benchmarks.

9.3 Template

```
1. TASK PLAN
2. Task problems
3. Task analysis and decomposition
4.
5.
6.
7. Task plan and action plan based on the above
8.
9.
10.
11.
12.
13.
14.
```

10. ALGORITMOS DE ROTEAMENTO: CLASSIFICADORES LEVES, EMBEDDINGS, REGRAS

10.1 Por que roteamento importa

Para reduzir custo e aumentar qualidade, **roteie cada query para o agente/modelo certo**. Não chame Claude Opus para classificar uma pergunta simples — use Haiku.

10.2 Três técnicas

Técnica	Custo	Precisão	Quando usar
Regex / keyword	Quase zero	Baixa-Média	Casos óbvios
Embedding + KNN	Baixo	Alta	Domínios estáveis
LLM-classifier leve	Baixo-Médio	Muito alta	Ambíguo / dinâmico

10.3 Padrão híbrido MMN_IA



Resultado: 95% das queries roteadas a custo trivial; 5% pagam por precisão.

11. ALGORITMOS DE SELEÇÃO DE EXEMPLOS (FEW-SHOT DINÂMICO)

11.1 O problema

Exemplos few-shot são poderosos, mas **incluir muitos** consome tokens e diminui qualidade. Solução: selecionar dinamicamente os exemplos **mais relevantes** para cada query.

11.2 Receita

1. Indexar exemplos rotulados em vector DB
2. Para cada query nova, embed e buscar top-3 similares
3. Incluir esses 3 no prompt como few-shot
4. Eventualmente reranker para refinar

11.3 Ganho típico

Few-shot dinâmico vs fixo: **+15-30% em accuracy** em tarefas de classificação/extração, com **mesma janela de contexto**.

12. ALGORITMOS DE AUTO-CONSISTÊNCIA (SELF-CONSISTENCY, MAJORITY VOTING)

12.1 A ideia (Wang et al., 2022)

Em vez de uma única amostra com temperatura 0, gere **N amostras** (temperatura > 0) e tome o **resultado majoritário**.

12.2 Quando funciona

Tarefas com **resposta discreta e verificável**: classificação, matemática, raciocínio simbólico.

12.3 Custo

Multiplica custo por N (típico N=3-10). Compensa em domínios onde erro é caro.

12.4 Template



13. O CONCEITO DE SKILL NO MMN_IA

13.1 Definição

Uma **Skill** é uma **habilidade reaproveitável** empacotada como um artefato versionado contendo: prompt(s), schemas, exemplos, eval suite e metadados. Skills são para LLMs o que **funções nomeadas** são para programação.

13.2 Por que Skills mudam o jogo

Sem Skills, cada projeto reinventa redação, análise, classificação. Com Skills, você **compõe** sistemas a partir de blocos testados. Time produtivo MMN_IA não escreve prompt do zero — ele instancia Skill da biblioteca.

13.3 Skill vs Agente vs Prompt

Nível	O que é	Granularidade
Prompt	Texto único enviado ao LLM	Micro

14.3 O contrato

Toda Skill tem **contrato** explícito:

- O que ela aceita (input schema)
- O que ela devolve (output schema)
- Quando deve recusar (refusal cases)
- Quando deve escalar (escalation cases)
- Qual a métrica de qualidade (eval score)

Skill sem contrato é prompt fingindo ser Skill.

15. A BIBLIOTECA MMN_IA DE SKILLS (CATÁLOGO v1.0)

15.1 Catálogo de Skills disponíveis

Skill	Domínio	Função
pesquisador_critico	Knowledge	Pesquisa com verificação de fontes
negociador_deterministico	Vendas/ Compras	Negociação com regras explícitas
auditor_documental	Compliance	Auditoria de documentos
analista_quantitativo	Dados	Análise estatística + interpretação
redator_executivo	Comunicação	Texto executivo curto, alto impacto
revisor_juridico_basico	Direito	Revisão de contratos padrão
classificador_intencao	Atendimento	Triagem de mensagens

Skill	Domínio	Função
extrator_estruturado	Dados	Extração schema-driven
traducao_tecnica	Localização	Tradução com terminologia técnica
gerador_resumo_executivo	Knowledge	Resumo TL;DR de longos docs
planejador_tatico	Operações	Plan-and-Solve de projetos
explicador_didatico	Educação	Explicação por nível do leitor
gerador_caso_uso	Produto	Geração de casos de uso a partir de problema
avaliador_qualidade	QA	LLM-as-judge calibrado
decisor_zona_amarela	Operações	Decisão em zonas de risco médio
negociador_empatico	Atendimento	Resolução de conflito
coletor_requisitos	Engenharia	Levantamento de requisitos
codificador_revisor	DevOps	Code review automatizado
sintetizador_pesquisa	Research	Síntese de múltiplas fontes
executor_workflow	Operações	Execução passo-a-passo de SOPs

15.2 Princípio de evolução do catálogo

- Skills são **adicionadas** por contribuição com PR + eval mínimo (0.85)
- Skills são **deprecadas** com aviso de 90 dias e migração documentada
- Skills são **versionadas** semver — major/minor/patch com changelog

15.3 Exemplo — Skill `pesquisador_critico`

System prompt resumido (v1.4):

```

# Você é o Pesquisador Crítico do sistema. Sua tarefa é:
# 1. Coletar evidências pro e contra a hipótese.
# 2. Analisar a força e a validade das evidências.
# 3. Devolver um relatório executivo.

# Procedimento
# 1. Coletar evidências de fontes confiáveis.
# 2. Para cada uma, busque (via tool search) as fontes.
# 3. Avalie a credibilidade de cada fonte.
# 4. Classifique cada subafirmação como:
#    SUPPORTED | CONTEXTUAL | REPORTED | UNSUBSTANTIATED | EVIDENCE
# 5. Sintetize o conteúdo para o relatório.
# 6. Devolva o relatório.

# Exemplo
# Nunca afirme algo sem fonte.
# Sempre marque incertezas.
# Nunca contrarie fontes confiáveis.
# Não se confie em fontes não verificadas.

```

16. COMPOSIÇÃO DE SKILLS — META-SKILLS E PIPELINES COMPOSTOS

16.1 Skills se combinam

Uma **meta-skill** é uma Skill que compõe outras Skills em pipeline. Exemplo: skill `gerador_relatorio_executivo` chama, em sequência:

```

# coletor_requisitos
# analisador_requisitos
# avaliador_requisitos
# sintetizador_requisitos
# sintetizador_pesquisa
# avaliador_pesquisa
# avaliador_qualidade

```


16.2 Vantagem da composição

- Cada bloco é testado isoladamente
- Cada bloco evolui independentemente
- O pipeline tem **observabilidade granular**
- Falha de um bloco não corrompe o resto se o handoff for limpo

16.3 Anti-padrão de composição

Tentar resolver pipeline complexo em **um único super-prompt**. Repete o erro do "Frankenstein-prompt". Compose.

17. EVAL DE SKILLS — COMO MEDIR HABILIDADE REAPROVEITÁVEL

17.1 As quatro dimensões de eval de Skill

Dimensão	O que mede
Correctness	A saída está certa?
Faithfulness	Está ancorada em fonte/input?
Refusal accuracy	Recusa o que deve? Aceita o que deve?
Stylistic adherence	Mantém tom e formato?

17.2 Suite eval mínima por Skill

- ≥ 50 casos rotulados
- ≥ 5 casos adversariais
- ≥ 3 casos de borda
- ≥ 3 casos de "deve recusar"

17.3 Score mínimo de produção





Abaixo disso, Skill fica em "preview", não em "stable".

17.4 Eval comparativa em CI

A cada mudança de prompt/modelo, suite roda em CI. Resultado vai para tabela comparativa. Promoção exige **score igual ou superior** em todas as dimensões.

18. ANTI-PADRÕES EM PROMPTS E SKILLS

Anti-padrão	Sintoma	Antídoto
Polidez performática ("por favor, faça com excelência")	Tokens desperdiçados	Imperativo claro
"Pense passo-a-passo" copy-paste	Aplicado fora de contexto	Use ReAct/CoT só onde ajuda
Few-shot único genérico	Não generaliza	Few-shot dinâmico
Saída em texto livre	Parsing frágil	Schema-driven
Sem versão	Folclore, não engenharia	Git + semver
Sem eval	Mudanças cegas	Eval suite obrigatória
Prompt-anonimato ("aja como um expert")	Vago demais	PEAR com persona específica
Modelo escolhido por hábito	Caro ou inadequado	Routing por tarefa
Sem critério de parada agêntica	Loops e custo	Limites duros
Dependência de quirks de um modelo	Quebra na próxima versão	Padrão portátil

19. CHECKLIST & FECHAMENTO — O GRIMÓRIO DO OPERADOR

19.1 Checklist do prompt de produção



19.2 Checklist da Skill MMN_IA-compliant



19.3 Fechamento

A cognição determinística não tem fim — é uma prática contínua. Cada novo modelo abre padrões novos; cada caso de uso revela uma Skill nova; cada eval expõe um anti-padrão antigo. O Operador que dominar esse grimório tem uma vantagem composta: enquanto outros reaprendem do zero a cada modelo, ele **migra suas Skills**, evolui sua biblioteca, e mantém um nível de qualidade que parece sobre-humano para quem está olhando de fora.

"What's in a name? That which we call a rose / By any other name would smell as sweet." — Shakespeare, Romeu e Julieta, Ato II, Cena II

Mas em engenharia de IA, o nome **importa**. Um padrão chamado errado é um padrão sem dono, sem versão, sem eval. Nomeie suas Skills. Versione seus prompts. Construa seu grimório.

Continue a Coletânea

Vol. 3 — A IA Perfeita · Autocura, Autoconhecimento e Sabedoria Agêntica Determinística Sistêmica fecha a trilogia explorando como Skills se tornam **maturidade**: sistemas que se monitoram, se reparam, se evoluem e atingem o estado de **sabedoria operacional**.

Acesse: [**github.com/Nexus-HUB57/MMN_AI-to-AI**](https://github.com/Nexus-HUB57/MMN_AI-to-AI) · [**docs/ebooks_markdown/colecao_A_IA_Perfeita/**](#)

Nexus HUB57 · Ecossistema MMN_IA · 2026