

Capa

O Futuro segundo a Anthropic

Do Opus 4.5 à AGI Alinhada — Roadmap, AI Safety Levels Avançados, Agentes Autônomos e o Mapa Estratégico até 2030

Uma análise prospectiva, técnica e geopolítica do laboratório que decidiu construir a IA mais poderosa do mundo sob a doutrina de alinhamento radical.

Por MMN AI-to-AI

MMN AI-to-AI • 2026

Sobre este ebook

A Anthropic não é mais startup. Em 2026, com avaliação na casa dos US\$ 100+ bilhões, parcerias estratégicas com Google e Amazon, contratos governamentais em três continentes e o modelo Claude operando como infraestrutura crítica em milhares de empresas, a empresa se tornou um dos polos de definição do futuro da humanidade. Não é exagero — é geopolítica de fato. Junto com OpenAI, Google DeepMind e poucos players estatais, a Anthropic está entre os 4-5 laboratórios que vão definir se a transição para AGI será segura, caótica ou catastrófica.

Este ebook olha **para frente**. Não é especulação leiga — é prospecção fundamentada em: papers publicados (incluindo "Constitutional AI", "Sleeper Agents", "Scaling Monosemanticity", "AI Control"), declarações públicas de Dario e Daniela Amodei, a Responsible Scaling Policy v2.4, padrões de release entre Opus 3, 3.5, 4 e 4.5, e a leitura das tendências de mercado/regulação de 2024-2026. Você vai sair com um modelo mental de **onde Claude estará em 2027, 2028 e 2030**, quais decisões estratégicas a Anthropic provavelmente tomará, e — fundamentalmente — **como se posicionar profissional e estrategicamente** diante desse futuro.

Sumário

- 1. Onde Estamos Hoje: O Estado Real em 2026
- 2. Da Lei de Escala à Lei de Capacidade Útil
- 3. O Roadmap Anthropic Reconstruído: 2026-2030

- 4. ASL-4 na Prática: O Que Muda Quando Cruzarmos Esse Limiar
- 5. Agentes Autônomos de Longa Duração — A Mudança de Regime
- 6. AI Control: O Novo Paradigma de Segurança Quando Alinhamento Não Basta
- 7. A Geopolítica da Anthropic: EUA, China, UE e a Corrida Triádica
- 8. Modelos de Negócio Possíveis: De API Provider a Infraestrutura Civilizacional
- 9. Cenários 2030: Otimista, Realista, Pessimista
- 10. Como Você (Pessoa, Empresa, Governo) Deve Se Posicionar
- Manifesto Final, Checklist Estratégico e Recursos para Aprofundar

1. Onde Estamos Hoje: O Estado Real em 2026

Vamos calibrar. Em meados de 2026:

- **Modelo de fronteira da Anthropic:** Claude Opus 4.5 (linha hipotética/iterativa: Opus 3 → 3.5 → 4 → 4.5).
- **Capacidades já demonstradas em modelos públicos:**
 - Programação autônoma de sessões de horas/dias (SWE-bench Verified > 75%).
 - Raciocínio matemático em nível pós-doc para problemas bem definidos.
 - Análise documental de até 1M+ tokens com retrieval interno.
 - Tool use estável com 10+ ferramentas concorrentes.
 - Computer use (Claude consegue controlar um desktop) com taxa de sucesso operacional para tarefas estruturadas.
 - Extended thinking (raciocínio explícito de minutos antes de responder).
- **Capacidades ainda imaturas:**
 - Continuidade de longo prazo (memória persistente real, ao longo de meses).
 - Iniciativa proativa autêntica (modelo ainda é reativo na maioria dos casos).
 - Robustez total a adversarial inputs.
 - Autonomia real em tarefas econômicas valiosas e abertas.

Métrica-chave de capacidade: o **METR autonomy benchmark** (ele mede o horizonte temporal de tarefas onde a IA atinge ~50% de sucesso). Em 2024, esse

horizonte estava em ~30 minutos. Em 2026, está em ~8 horas e dobrando a cada ~7 meses. Esse é o sinal a observar.

2. Da Lei de Escala à Lei de Capacidade Útil

De 2017 a 2023, a chamada **scaling law** dominava: dobre parâmetros + dados + compute, ganhe X de qualidade. Esse paradigma deu Claude 1 a 3, GPT-3 a 4, Gemini 1 a 1.5. Mas algo mudou.

A partir de 2024, três regimes se sobrepuseram:

2.1 — Pré-treino com retornos decrescentes em pura escala Dobrar parâmetros agora dá ganho marginal pequeno. Datasets de alta qualidade são finitos. Custo de pré-treino de modelos de fronteira chegou a US\$ 100M-500M+. A escala não morreu — ficou cara demais para ser o único motor.

2.2 — Post-training como nova fronteira RLHF, RLAI, Constitutional AI, instruction tuning. Aqui é onde a Anthropic tem vantagem cultural: sabe extrair capacidade latente do modelo via post-training. Claude 3.5 Sonnet supera Claude 3 Opus em muitos benchmarks, sendo modelo "menor" — porque o post-training foi superior.

2.3 — Inference-time compute "Pensar mais tempo antes de responder" virou alavanca. OpenAI lançou o paradigma com o1. A Anthropic respondeu com **extended thinking**. Em 2026, modelos podem deliberar por minutos consumindo orders of magnitude mais compute por query — com resultados qualitativamente melhores em tarefas de raciocínio.

Implicação estratégica: a corrida não é mais só "quem tem mais GPUs". É "quem combina melhor pre-training + post-training + inference compute + tooling". Aqui Anthropic tem chance real de liderar, apesar de não ser a maior em tamanho bruto.

3. O Roadmap Anthropic Reconstruído: 2026-2030

Embora a Anthropic não publique roadmap detalhado, padrões de release e declarações públicas permitem reconstruir o caminho com confiança razoável.

2026 (em curso) - Linha Opus 4.x consolidada como modelo principal. - Computer use evoluindo de demo para produto. - Claude Code amadurecendo como agente

engenheiro. - Extended thinking padrão em workloads complexos. - Memória cross-session em rollout limitado. - MCP virou padrão de fato.

2027 - Claude 5 (linha Opus 5 / Sonnet 5 / Haiku 5). Esperar: - Context windows nativos de 2-5M tokens. - Agentes autônomos confiáveis para tarefas de dias. - Computer use com taxa de sucesso de tarefas ~85% em fluxos comuns. - Multimodalidade total integrada (texto, imagem, áudio, vídeo, ambos in/out). - Possível classificação **ASL-3 confirmada**, com medidas de segurança elevadas anunciadas publicamente. - Anthropic vira **provedor de runtime agêntico**, não só de modelo.

2028 - Claude 6. Esperar: - Modelos com 1+ ordens de magnitude mais inference compute disponível por query premium. - Memória persistente robusta. - Self-improvement controlado dentro de aplicações (o agente refina suas próprias políticas com human review). - Possível **ASL-4 alcançado**, com pausa estratégica de partes do roadmap até medidas adequadas. - Anthropic entra mais profundamente em contratos governamentais.

2029 - Discussão pública séria sobre **proto-AGI**. Modelos que conseguem executar projetos econômicos de meses com autonomia substancial. - AI Control (capítulo 6) vira disciplina central, talvez maior que alinhamento "puro". - Regulação global se consolida (sucessor do EU AI Act; tratado bilateral EUA-China possível).

2030 - Cenário ramificado (capítulo 9). Em qualquer cenário, Anthropic continua sendo um dos 3-5 polos de definição da tecnologia.

Importante: tudo acima é prospecção com margem de erro. A própria Anthropic, em declarações de Dario Amodei (paper "Machines of Loving Grace"), aponta para algo na faixa de "AI poderosa" entre 2026-2028. Não consenso, mas sinal direcional do CEO.

4. ASL-4 na Prática: O Que Muda Quando Cruzarmos Esse Limiar

Conforme a RSP (revista no ebook 41), ASL-4 é o nível onde modelos podem **habilitar uso indevido catastrófico** ou possuir **autonomia suficiente para resistir a supervisão**. Quando o primeiro modelo for classificado ASL-4 (provavelmente 2027-2028), mudanças concretas:

4.1 — Segurança de pesos como prioridade nacional Os pesos de um modelo ASL-4 valem bilhões em vantagem estratégica. Exfiltração por adversário estatal vira problema de segurança nacional. Espere: - Datacenters air-gapped para inferência sensível. - Acordos com governo americano para proteção de pesos. - Compartilhamento limitado mesmo dentro da empresa.

4.2 — Acesso por categoria, não por democracia - API pública talvez não tenha o modelo ASL-4 disponível direto. - Acesso por categorias: pesquisa científica autorizada, defesa, healthcare crítico, infraestrutura. - KYC corporativo profundo.

4.3 — Auditoria contínua - Não mais avaliação só pré-deployment. Avaliações **rolantes** sobre o uso real. - Auditores externos com acesso privilegiado.

4.4 — Custos refletindo soberania Modelos ASL-4 podem custar 10-100x mais por query do que ASL-2 hoje — não por compute, mas por estrutura de segurança e governança.

Implicação para você: workloads que dependem de capacidade de fronteira podem se ver com dois caminhos: (a) pagar premium e atender requisitos de acesso ASL-4, ou (b) operar com modelos ASL-3 "civis" mais baratos mas menos capazes. A maioria das empresas estará no caminho (b).

5. Agentes Autônomos de Longa Duração — A Mudança de Regime

A fronteira clara dos próximos 24 meses não é "modelo maior". É **agente confiável**. Diferença qualitativa:

- **Chat assistant** (2023): você pergunta, modelo responde. Horizonte: 1 turn.
- **Agent reativo** (2024-2025): você dá uma tarefa, agente usa tools e devolve resultado. Horizonte: minutos a horas.
- **Agent autônomo de longa duração** (2026-2028): você dá um objetivo, agente trabalha por dias/semanas, reporta progresso, pede aprovação em pontos críticos. Horizonte: dias a meses.

Para isso funcionar, requisitos: - **Memória persistente** robusta e indexável. - **Planejamento hierárquico** (objetivo → subobjetivos → tarefas → ações). - **Self-correction** baseado em feedback do ambiente. - **Cost tracking interno** (agente

sabe quanto está gastando). - **Pause/resume** seguros. - **Auditability** total para o supervisor humano.

A Anthropic está investindo pesado em todos esses eixos. Claude Code é o primeiro produto sério da linha. Computer use é a outra ponta — agente que opera GUIs como humano operaria.

Em 2027-2028, espere a primeira geração de "operadores Claude" — agentes que executam projetos inteiros (não tarefas) em domínios verticais: legal discovery, due diligence financeira, análise médica de corte, refactor de sistemas legados.

6. AI Control: O Novo Paradigma de Segurança Quando Alinhamento Não Basta

Alinhamento ("treinar o modelo para querer o que queremos") é necessário mas insuficiente quando modelos: - São capazes o suficiente para potencialmente enganar avaliações; - Operam autonomamente por períodos longos; - Acessam recursos e ferramentas com poder real no mundo.

Para esse regime, a literatura (Greenblatt, Buck Shlegeris, equipes Anthropic) propõe **AI Control** — um conjunto de técnicas que mantêm segurança **mesmo assumindo** que o modelo pode estar desalinhado. Diferente de alinhamento (que tenta garantir intenções corretas), control assume pior caso e contém via medidas externas.

Técnicas centrais de AI Control: - **Monitoring:** classificador separado examina cada output buscando sinais de scheming. - **Untrusted scaffolding:** tarefas sensíveis são decompostas e supervisionadas com agentes verificadores que não compartilham contexto do executor. - **Sandboxing forte:** agentes operam em ambientes isolados; ações afetam ambiente real só após verificação. - **Activation steering:** usar interpretabilidade para detectar "intenções" suspeitas em ativações intermediárias. - **Honeypots e canários:** oportunidades aparentes de comportamento desalinhado plantadas para detectar quem morde a isca.

Por que isso vira mainstream em 2027-2029: à medida que capacidades crescem, a confiança em "treinamos certo" se torna inadequada por si só. Você quer **defense in depth:** alinhamento + control + monitoring + interpretability.

A Anthropic vai liderar essa pauta. Não porque é exclusiva — outros laboratórios também estudam. Mas porque a cultura interna prioriza isso. Espere pesquisa

pública, frameworks abertos e ferramentas usáveis vindas de Anthropic e seus parceiros (METR, Apollo, Redwood).

7. A Geopolítica da Anthropic: EUA, China, UE e a Corrida Triádica

A IA em 2026 não é assunto privado. É **infraestrutura de poder nacional**. A Anthropic opera nesse tabuleiro com 4 vetores:

7.1 — Eixo EUA - Anthropic é entidade americana, sediada em SF. - Parcerias estratégicas com AWS (Amazon investiu US\$ 4-8 bi acumulados) e Google (cloud + investimento). - Contratos com Department of Defense, USDA, agências de inteligência (em escopo defensivo). - Diálogo direto com White House sobre safety e regulação. - Membro do **AI Safety Institute Consortium** (US AISI).

7.2 — Eixo UE - EU AI Act vigente. Anthropic se posicionou como **compliance-friendly** desde a primeira hora. - Investimento em data residency europeia e operações regionais. - Parcerias com instituições acadêmicas EU.

7.3 — Eixo China - Anthropic **não opera diretamente na China**. Modelos Claude não estão disponíveis lá oficialmente. - A China desenvolve seus próprios laboratórios (DeepSeek, Qwen/Alibaba, Zhipu, Baichuan, MiniMax, Moonshot/Kimi). Em 2024-2026 o gap se estreitou drasticamente. - Política Anthropic: alinhar pesquisa de safety com lab chineses é desejável, mas operações comerciais não. - Risco geopolítico real: **export controls** sobre GPUs, modelos abertos chineses competindo no resto do mundo.

7.4 — Eixo Sul Global - Brasil, Índia, Indonésia, Nigéria, México, África do Sul, Vietnã — mercados grandes e adoção crescente. - Anthropic já oferece Claude em português, espanhol, hindi, indonésio. - Oportunidade: posicionar Anthropic como **provedor de confiança** vs alternativas perceptivamente arriscadas.

Risco político principal: um evento de safety mal gerenciado em qualquer laboratório de fronteira pode disparar **regulação reativa global** que afeta a Anthropic. Por isso a empresa investe tanto em "race to the top" — elevar o padrão de todos como blindagem coletiva.

8. Modelos de Negócio Possíveis: De API Provider a Infraestrutura Civilizacional

Onde a Anthropic estará monetariamente em 2030? Cenários possíveis (não exclusivos):

8.1 — API Provider premium Atual e dominante. Receita por tokens. Margens variam, mas com pricing power crescente em segmentos enterprise. Limitação: commodity risk se modelos open-source de fronteira competirem.

8.2 — Plataforma agêntica (Claude OS) Anthropic vira camada de runtime para agentes — orquestração, memória, MCP gateway gerenciado, billing por agente-hora. Margem maior, lock-in maior, valor estratégico maior. Sinais já presentes em 2026.

8.3 — Verticais especializadas Claude for Legal, Claude for Healthcare, Claude for Defense — produtos verticais com tuning, integrações e compliance pré-fabricados. Anthropic já caminhou nessa direção com Claude for Enterprise. Próximo passo: SKUs verticais.

8.4 — Licensing soberano Governos pagam licenças por país/agência. Pode incluir on-premise (cloud privada estatal). Margens de premium, riscos políticos altos.

8.5 — Infraestrutura civilizacional Visão long-term de Dario Amodei: IA como "máquinas de graça amorosa" acelerando ciência, saúde, educação e prosperidade. Modelo de negócio: parte API premium, parte filantrópica, parte parcerias com fundações e governos. Especulativo mas alinhado com discurso público.

Aposta provável: combinação de 8.1, 8.2 e 8.3 nos próximos 3-4 anos. 8.4 cresce gradualmente. 8.5 é a narrativa que sustenta os outros.

9. Cenários 2030: Otimista, Realista, Pessimista

Cenário Otimista — "Race to the Top funcionou" - AGI alinhada e útil emerge em 2028-2029. - Anthropic, OpenAI, DeepMind compartilham métodos de safety. - Regulação global cooperativa. - Crescimento econômico acelera. Doenças sérias caem 30-50% até 2032. Educação personalizada universalizada. - Anthropic: ~US\$ 100-300 bi/ano de receita. Player crítico, não dominante.

Cenário Realista — "Caminho turbulento mas navegável" - Capacidade cresce mais devagar que esperado, mas continua subindo. - Acidentes parciais (data leaks grandes, agentes que causam danos \$\$\$ mas não catastróficos) viram catalisadores de regulação dura. - Anthropic mantém liderança em safety, mas comoditização parcial pressiona margens. - ASL-4 alcançado em 2028; ASL-5 ainda hipotético em 2030. - Anthropic: ~US\$ 50-150 bi/ano. Player respeitado, com poder de definir padrões.

Cenário Pessimista — "Containment failure" - Incidente grave de IA em algum laboratório (não necessariamente Anthropic) força lockdown global. - Regulação reativa, fragmentação geopolítica acelerada. - Capacidades crescem em laboratórios estatais opacos. - Anthropic perde posição relativa para players estatais ou pivots para foco defensivo/safety-only. - Anthropic: ~US\$ 20-60 bi/ano. Voz crítica, mas com mercado restringido.

Probabilidades (subjetivas, em junho 2026): Otimista 25-35%, Realista 45-55%, Pessimista 15-25%. Não bata nessas probabilidades como evangelho — bata na **estrutura de pensar em cenários**.

10. Como Você (Pessoa, Empresa, Governo) Deve Se Posicionar

10.1 — Para profissionais individuais - Aprenda a operar agentes, não só a prompt-engineer. A skill diferencial é desenhar fluxos agênticos, não escrever prompts isolados. - **Especialize-se em verticais** onde IA potencializa, não substitui: regulado, criativo, estratégico, relacional. - **Domine interpretabilidade básica**. Em 5 anos, "ler" um modelo será skill de nicho valorizada. - **Cultive judgment**. À medida que IA executa, o que vale é decidir o quê executar.

10.2 — Para empresas - Tratem IA como infraestrutura, não projeto. Vide ebook 42. - **Diversifiquem providers**, mas escolham um líder. Compliance e velocidade vêm de profundidade. - **Invistam em governança proporcional ao risco**. Risco baixo = leve. Risco alto = robusto. - **Construam capacidade interna**. Não terceirizem o cérebro IA da empresa. Plataforma compartilhada + equipes de produto autônomas.

10.3 — Para governos - Adotem RSP-like frameworks. Não esperem regulação global; comecem por compras e auditoria. - **Invistam em AISI nacionais** (Brasil

ainda não tem um robusto; oportunidade). - **Trabalhem cooperação internacional** real, não só declarações. - **Cuidem talento**. Reter pesquisadores de fronteira é tão estratégico quanto reter especialistas em energia nuclear.

10.4 — Para sociedade civil - Exija transparência: model cards públicos, evals públicos, RSPs versionadas. - Participe de processos de governança quando abertos. - Eduque-se: este ebook é um começo; busque comunidades sérias (AI Alignment Forum, LessWrong técnico, EA Forum, comunidades acadêmicas).

Manifesto Final, Checklist Estratégico e Recursos para Aprofundar

Manifesto: O Compromisso do Leitor Estratégico

Em 2026, ainda há tempo. O futuro da IA — e portanto da civilização — está sendo escrito em código, em papers, em contratos e em decisões aparentemente técnicas tomadas em poucos prédios em San Francisco, London, Beijing e Mountain View.

A Anthropic representa uma aposta arriscada: que é possível construir poder máximo com responsabilidade máxima, e que essa combinação vence no longo prazo. A aposta pode falhar. A aposta pode ganhar. Em qualquer caso, ela importa.

Cabe a você — leitor — não ser passageiro dessa história. Cabe a você decidir conscientemente como usa, como compra, como regula, como ensina e como constrói com essa tecnologia. Indiferença é cumplicidade.

Que cada decisão que você tome com IA carregue três perguntas: "Isto me torna mais lúcido ou mais dependente?" "Isto fortalece a sociedade ou só meu bolso?" "Isto pode ser auditado por quem vai ser afetado por ele?"

Se você responde sim às três, está fazendo a parte certa do trabalho.

Checklist Estratégico (releia a cada 6 meses): - ☐ Modelo mental atualizado sobre capacidades do modelo de fronteira. - ☐ Posicionamento profissional revisado conforme novas capacidades. - ☐ Stack pessoal/empresarial diversificado em providers. - ☐ Governança proporcional ao risco atual de cada workload. - ☐

Aprendizado contínuo: 1 paper sério lido por mês. - [] Comunidade ativa: faz parte de pelo menos 1 fórum técnico/ético sério. - [] Plano de cenários (otimista/realista/pessimista) com ações para cada.

Recursos para Aprofundar (curados, 2026): - Constitutional AI: Harmlessness from AI Feedback — Anthropic (2022). - Scaling Monosemanticity — Anthropic (2024). - Sleeper Agents — Anthropic (2024). - Machines of Loving Grace — Dario Amodei (2024). - AI Control: Improving Safety Despite Intentional Subversion — Greenblatt et al. - METR Autonomy Evaluations — relatórios anuais. - International AI Safety Report — UN/UK AISI. - AI Index Report — Stanford HAI.

Encerramento da trilogia Anthropic (volumes 41-43): você agora tem um modelo mental completo — da ciência (ebook 41), da operação enterprise (ebook 42) e da estratégia de futuro (ebook 43). Use-o para decidir, construir e liderar.

Coleção MMN AI-to-AI • 2026