

Próximos 5 anos da IA

A janela imediata: copilotos, agentes e governança

Slug: cf-01-proximos-5-anos

Capa do ebook

Capa

O que se esperar das IAs nos próximos 5 anos?

Horizonte 2026-2031: O Quinquênio da Inteligência Agêntica
Onipresente — Mapas de Tendências, Marcos Técnicos e Condutas
Práticas

Não é ficção científica. É a leitura fria do que já está em laboratório, em produção ou em roadmap público — e do que cada um de nós deve fazer antes que chegue.

Por MMN AI-to-AI

MMN AI-to-AI • 2026

Sobre este ebook

A próxima metade da década de 2020 será, com altíssima probabilidade, **a mais transformadora da história humana desde a revolução industrial**. A inteligência artificial deixou de ser promessa de laboratório e se tornou infraestrutura. Modelos de raciocínio, agentes autônomos, IA multimodal generativa, robótica humanoide, IA científica, IA médica personalizada — tudo isso já existe em 2026. A pergunta não é mais "**se**" essas tecnologias vão se

consolidar, mas **quando, como e o que cada um de nós deve fazer agora** para não ser atropelado por elas.

Este primeiro ebook da coletânea "**O que se esperar das IAs nos próximos anos?**" cobre o horizonte de **5 anos (2026-2031)**. O método é claro: nada de especulação solta, nada de futurismo de café. Cada afirmação tem base em **três pilares**: (1) o que **já existe** em produção hoje; (2) o que está **em roadmap público** de empresas líderes; (3) o que a **literatura científica revisada por pares** e os relatórios de tendência (Stanford AI Index, McKinsey, BCG, Anthropic, OpenAI, DeepMind) projetam como provável. Onde a projeção exigir extrapolação, dizemos explicitamente que é extrapolação — e marcamos o nível de confiança.

Sumário

- 1. O Método: Como Projetamos o Curto Prazo em IA
- 2. O Estado da Arte em 2026: O Que Já Funciona
- 3. Agentes Autônomos: A Onda que Vai Engolir o Trabalho Cognitivo
- 4. IA Multimodal Generativa: Texto, Imagem, Vídeo, Áudio, 3D, Ação
- 5. Robótica Humanoide: Saindo do Laboratório
- 6. IA na Saúde, Educação, Direito e Ciência
- 7. Infraestrutura: Chips, Energia, Data Centers
- 8. Regulação, Ética e Governança
- 9. O Que Fazer nos Próximos 5 Anos: Guia Pessoal e Profissional
- 10. Riscos Reais no Horizonte 2031 e Como Mitigá-los

1. O Método: Como Projetamos o Curto Prazo em IA

Por que 5 anos é o horizonte mais difícil (e mais valioso)

Projetar o curto prazo em IA é mais difícil do que o longo prazo. Por quê? Porque no curto prazo, **estamos lidando com engenharia e produto**, não com leis da física. Mudanças regulatórias, falhas de mercado, 瓶颈s de infraestrutura e até decisões pessoais de líderes de laboratório podem acelerar ou atrasar tendências em meses. Já no longo prazo, leis da física e da biologia se impõem.

Ainda assim, 5 anos é o horizonte mais **acionável**: é onde mora a decisão de carreira, o investimento, o posicionamento profissional, a estratégia de empresa. Por isso usamos um método rigoroso.

Os 3 pilares da projeção

1. **Pilar 1: O que já existe.** Se algo está em produção em 2026, tende a estar mais barato, mais rápido e mais difundido em 5 anos. Lei de Wright, curva de aprendizado, economias de escala.
2. **Pilar 2: O que está em roadmap público.** OpenAI, Anthropic, Google DeepMind, Meta, Mistral e xAI publicam papers e planos plurianuais. Quando eles dizem que estão construindo, a probabilidade de entrega em 2-3 anos é alta.
3. **Pilar 3: O que a ciência e a economia projetam.** Stanford AI Index, relatórios da McKinsey, BCG, Goldman Sachs, Sequoia, Ark Invest, UNESCO, OECD. Quando múltiplas fontes independentes convergem, a confiança é alta.

Os 4 limites honestos do método

- **Inovações disruptivas não previstas.** A próxima revolução pode vir de onde ninguém espera (ex: Transformers em 2017, ChatGPT em 2022, agentic loops em 2024).
- **Eventos geopolíticos.** Guerras, sanções, rupturas de 供应链 podem acelerar ou frear tendências.
- **Decisões humanas individuais.** Um único líder de laboratório pode mudar o rumo da indústria.
- **Acidentes e incidentes.** Falhas catastróficas, regulamentações de emergência, crises de confiança pública.

Por isso, todo capítulo termina com "**O que pode dar errado**" — o cenário alternativo em que a projeção se inverte.

2. O Estado da Arte em 2026: O Que Já Funciona

O inventário do que já está maduro

Em 2026, as seguintes tecnologias **já são realidade de produção** (não promessa):

Modelos de linguagem de raciocínio profundo: - Claude Opus 4, GPT-4.1, Gemini 2.5 Pro Deep Think, o3, DeepSeek R1, Llama 4 Reasoning. - Resolvem problemas complexos de matemática, lógica, programação e estratégia com precisão de PhD em muitas áreas.

Modelos multimodais generativos: - Texto (Claude, GPT, Gemini). - Imagem (Midjourney v7, FLUX 1.1 Pro, DALL-E 4, Imagen 4, Ideogram 2). - Vídeo (Sora 2, Veo 3, Runway Gen-4, Kling 2.0, Pika 2.5). - Áudio (ElevenLabs, Suno v4, Udio 2, Cartesia, MiniMax Speech). - 3D (Tripo, Meshy, Rodin, Genie 2 da DeepMind, World Labs). - Ação (Agentes com computer use, browser use, robotic control).

Agentes autônomos em produção: - 11x.ai, Artisan, Regie.ai, Decagon, Sierra, Forethought: SDRs e suporte autônomos. - Devin, Replit Agent, v0, Lovable, Bolt.new: codificação autônoma. - Harvey, Spellbook: jurídico. - Hippocratic AI, Glass Health: saúde. - Glean, Sana: busca corporativa e conhecimento.

Infraestrutura: - vLLM, TGI, Ollama, LM Studio: inferência local. - Pinecone, Weaviate, Qdrant, Chroma, pgvector: vector DBs. - LangChain, LlamaIndex, LangGraph, CrewAI, AutoGen: orquestração. - AWS Bedrock, Azure AI Foundry, Google Vertex AI: plataformas enterprise.

Chips: - NVIDIA Blackwell B200/B300, H200, GB200 NVL72. - AMD MI400 series, Intel Gaudi 3. - TPUs v6, v7 do Google. - Trainium3 da AWS, Maia da Microsoft. - Cerebras CS-3, Groq LPU, SambaNova SN40L.

Implicação imediata: tudo isso vai se tornar commodity em 3-5 anos.

3. Agentes Autônomos: A Onda que Vai Engolir o Trabalho Cognitivo

O que vai acontecer (com alta confiança)

Em 5 anos, **a maior parte do trabalho cognitivo de rotina será feita por agentes autônomos**. Não vai ser uma revolução de um dia --- vai ser uma sequência rápida de substituições incrementais, análoga à automação industrial do século XX, mas em velocidade 10x maior.

Substituições quase certas até 2031:

- **Atendimento ao cliente nível 1 e 2:** 80% substituído por agentes (já está em 50% em 2026).
- **SDRs e BDRs de vendas outbound:** 70% substituído por agentes.
- **Análise de currículos e triagem inicial de RH:** 90% automatizado.
- **Geração de relatórios, dashboards, e-mails transacionais:** 95% automatizado.
- **Codificação de boilerplate, testes unitários, documentação:** 90% automatizado.
- **Contas a pagar/receber, conciliação, fechamento contábil mensal:** 85% automatizado.
- **Triagem jurídica inicial, pesquisa de jurisprudência, due diligence:** 80% automatizado.
- **Análise de imagem médica (raio-X, tomografia, dermatologia):** 95% automatizado.
- **Tradução simultânea de baixa e média complexidade:** 99% automatizado.

Substituições parciais (humano + IA, com humanos no loop):

- Diagnóstico médico final.
- Estratégia corporativa de alto nível.
- Pesquisa científica de fronteira.
- Criatividade publicitária e editorial de campanha.
- Liderança, gestão de pessoas, negociação complexa.

Trabalhos que vão crescer (com altíssima confiança):

Engenharia de IA: prompt engineering, agent design, MLOps, AI safety, AI security.

- **Treinamento e fine-tuning de modelos para domínios verticais.**
- **Auditoria de IA:** assurance, governança, conformidade.
- **Curadoria humana de IA:** revisão, validação, ajuste fino de saídas automatizadas.
- **Engenharia de dados sintéticos:**

gerar, validar, curar datasets. - **AI ops / SRE de IA:** monitorar, manter, otimizar sistemas em produção. - **Produtos e 商业模式 baseados em IA:** quem monta SaaS, marketplaces, agências sobre IA.

O que pode dar errado: regulamentação pode frear substituição em áreas sensíveis (saúde, jurídico, educação). Resistência cultural pode preservar certas profissões por mais tempo.

4. IA Multimodal Generativa: Texto, Imagem, Vídeo, Áudio, 3D, Ação

O que vai acontecer

A próxima fronteira é a **fusão de todas as modalidades em um único modelo "de mundo"**. Hoje, modelos processam texto, imagem, vídeo, áudio, 3D e ação separadamente ou em pares. Em 5 anos, **o modelo padrão vai processar e gerar todas essas modalidades simultaneamente**, com memória de longo prazo entre elas.

Marcos prováveis até 2031:

2026-2027: - Modelos que geram vídeo de 5-10 minutos com consistência narrativa completa. - Avatares digitais indistinguíveis de humanos em chamadas de vídeo (deep real-time). - Dublagem automática de filmes preservando voz e emoção. - Geração 3D a partir de texto em segundos, com textura e física realistas.

2028-2029: - Modelos "de mundo" (world models) que simulam física, causa-efeito, intenção humana. - IA que assiste a um vídeo de 2 horas e responde perguntas específicas com raciocínio complexo. - Geração de jogos 3D completos a partir de prompt de uma frase. - Robôs que aprendem novas tarefas assistindo a um único vídeo de demonstração.

2030-2031: - Modelos que entendem contexto multimodal de horas, mantendo coerência total. - Geração de filmes inteiros com IA (roteiro, direção, atores, edição, trilha) --- mas com humano no comando criativo. - Simuladores de mundo (world simulators) usados em treinamento corporativo, militar, médico. - Realidade virtual totalmente gerada por IA em tempo real.

Implicações: democratização massiva da produção audiovisual, jornalística, educacional, publicitária. Queda brutal de custo de produção de conteúdo. Surgimento de novos formatos (narrativas personalizadas, jogos infinitos, simuladores imersivos).

O que pode dar errado: crise de direitos autorais, desinformação em escala industrial, regulamentação de deepfakes, esgotamento de dados de treino.

5. Robótica Humanoide: Saindo do Laboratório

O que vai acontecer

2026 é o ano em que a robótica humanoide **passa de demo viral para produto de mercado**. Tesla Optimus, Figure 02, 1X Neo, Appteronik Apollo, Unitree H1, Sanctuary Phoenix, Agility Digit, Boston Dynamics Atlas (versão elétrica) já estão em pilotos industriais.

Marcos prováveis até 2031:

2026-2027: - Primeiras mil unidades de humanoides operando em fábricas (logística, montagem, inspeção). - Custo unitário cai de US\$ 200K para US\$ 50K-80K. - Tarefa única (pegar peça, mover caixa, montar componente) com 95%+ de sucesso.

2028-2029: - 100 mil a 500 mil unidades operando globalmente. - Custo cai para US\$ 20K-30K. - Tarefas múltiplas em ambientes semi-estruturados (lojas, hotéis, hospitais, armazéns). - Coordenação em frotas (multi-robô) com IA central.

2030-2031: - 1-5 milhões de unidades. - Custo cai para US\$ 10K-15K (acessível para PMEs). - Operação em ambientes domésticos e de serviço (limpeza, cozinha, entrega, cuidado de idosos). - Primeiros exoesqueletos e próteses inteligentes com IA integrada para o consumidor.

Impacto: substituição de trabalho físico repetitivo (logística, manufatura, limpeza, entrega, construção, agricultura). Novo paradigma de "robô como 同僚". Surge a "robótica como serviço" (RaaS).

O que pode dar errado: acidentes em larga escala, rejeição pública, regulamentação de segurança, 瓶颈s de 供应链 de atuadores e baterias.

6. IA na Saúde, Educação, Direito e Ciência

O que vai acontecer (área por área)

Saúde: - **Diagnóstico por imagem:** 95% automatizado até 2028. -

Triagem de sintomas e anamnese inicial: agente IA em 80% dos consultórios. - **Descoberta de medicamentos:** ciclo de 10 anos cai para 2-3 anos. AlphaFold 3, ESM-3, modelos generativos de proteínas e moléculas. - **Cirurgia assistida por robô + IA:** 30% das cirurgias em 2031 com algum grau de autonomia assistida. - **Medicina personalizada:** sequenciamento genômico + IA de fenotipagem por imagem para tratamento custom.

Educação: - **Tutor IA pessoal:** presente em 60% das escolas até 2031. Khanmigo, MagicSchool, Quill, EdSynth, Khan Academy, Duolingo Max. - **Currículo adaptativo:** ajusta em tempo real ao ritmo do aluno. - **Avaliação automatizada de redações, projetos, apresentações.** - **Acesso universal a educação de qualidade em idiomas locais,** mesmo em regiões remotas. - **Certificação de competências baseada em evidências,** não em horas de aula.

Direito: - **Pesquisa jurídica:** 95% automatizada. - **Análise de contratos:** 90% automatizada. - **Redação de peças:** 70% automatizada. - **Due diligence, KYC, compliance:** 90% automatizado. - **Mediação online:** agente IA em disputas de baixo valor.

Ciência: - **IA como copiloto de pesquisa:** sugestão de hipóteses, revisão de literatura, geração de código experimental, análise de dados. - **Laboratórios autônomos:** A-Lab da DeepMind, Coscientist, ChemCrow. IA planeja, executa e analisa experimentos físicos. - **Aceleração de papers, revisão por pares, meta-análise.** - **Climate science, materiais, energia, fusão nuclear:** IA acelera drasticamente P&D.

O que pode dar errado: regulamentação rígida em profissões protegidas (medicina, direito, contabilidade) pode atrasar adoção. Falhas de IA em diagnóstico podem ter consequências graves, exigindo cautela.

7. Infraestrutura: Chips, Energia, Data Centers

O que vai acontecer

A demanda por computação de IA está crescendo **10x a cada 2 anos**. Isso pressiona três frentes: **chips, energia e data centers**.

Chips: - **NVIDIA mantém liderança** até pelo menos 2028. Blackwell, Rubin, Feynman (próxima geração). - **AMD, Intel, Google, Amazon, Microsoft** ganham participação com chips customizados. - **Chips especializados** (Groq, Cerebras, SambaNova, Tenstorrent) ganham nichos em inferência ultrarrápida. - **China** acelera com Huawei Ascend, Cambricon, Moore Threads, Biren --- apesar das sanções. - **Primeiros chips fotônicos** (Lightmatter, Lightelligence) em produção comercial. - **Lei de Huang:** performance por watt dobra a cada 2-3 anos.

Energia: - Consumo global de data centers de IA: **3% a 8% da eletricidade mundial** até 2031 (era 1,5% em 2025). - Demanda por **energia firme** (nuclear, geotérmica, hidrelétrica) cresce exponencialmente. - **Pequenos reatores modulares (SMRs)** e reatores de fusão experimental começam a alimentar data centers. - Data centers se tornam **prosumidores** (produzem e vendam energia, estabilizam rede).

Data centers: - Construção global acelera: **US\$ 1 trilhão em data centers de IA** até 2030 (estimativa McKinsey). - Localização: perto de energia barata (norte dos EUA, Canadá, países nórdicos, Oriente Médio, Brasil). - **Refrigeramento líquido** vira padrão. - **Data centers orbitais** (Lumen Orbit, Starcloud) começam pilotos.

O que pode dar errado: crise energética global, 瓶颈 de fábrica de chips (TSMC Arizona, Samsung Texas, Intel Ohio), geopolítica (Taiwan), custos que inviabilizam projetos.

8. Regulação, Ética e Governança

O que vai acontecer

A regulação de IA **vai se consolidar em blocos regionais**, com filosofias diferentes:

EUA (até 2031): - Lei federal de IA passa no Congresso (provavelmente em 2027-2028). - Padrões de segurança obrigatórios para modelos acima de threshold de compute. - AI Safety Institute vira agência permanente. - Exigências de transparência, red-teaming, avaliação pré-deploy. - Regulação setorial: saúde (FDA), financeiro (SEC), educação (Dept of Education).

União Europeia (até 2031): - AI Act em plena execução. Atualizações em 2027, 2029. - Multas pesadas por violação (até 7% do faturamento global). - Padrão global de facto --- o "Brussels Effect" da IA.

China (até 2031): - Regulação por código (algorítmica), não por lei escrita. - Exigência de alinhamento com valores socialistas, segurança nacional. - Liderança em IA generativa aberta (Qwen, DeepSeek, GLM, Yi, Baichuan). - Padrão de IA "soberana" exportado para Sul Global.

Brasil e América Latina (até 2031): - PL de IA brasileiro aprovado (provavelmente 2027-2028). - Regulamentação da ANPD ganha força. - Sandbox regulatório para inovação. - Brasil vira hub de IA em português e para o Sul Global.

Padrões técnicos globais: - ISO/IEC 42001 (gestão de IA) vira referência mundial. - NIST AI Risk Management Framework adotado em dezenas de países. - Convenções internacionais sobre IA militar, IA em armas, IA em crianças.

O que pode dar errado: fragmentação regulatória excessiva, corrida armamentista, captura regulatória por big tech.

9. O Que Fazer nos Próximos 5 Anos: Guia Pessoal e Profissional

Ações práticas (por perfil)

Se você é profissional liberal / autônomo: 1. Adote IA generativa no trabalho HOJE. Não em 6 meses. HOJE. 2. Identifique as 3 tarefas mais demoradas do seu trabalho e automatize com IA em 90 dias. 3. Crie um portfólio de projetos com IA --- mesmo que não tenha cliente. 4. Acompanhe 1 fonte confiável por semana (newsletter, podcast, canal). Não tente absorver tudo. 5. Construa uma audiência (LinkedIn, YouTube, newsletter, podcast) mostrando o que você faz com IA. Autoridade técnica + visibilidade = diferencial competitivo imparável.

Se você é empreendedor / empresário: 1. Mapeie todas as áreas da empresa que podem ser automatizadas. Faça um inventário de "trabalho cognitivo de rotina". 2. Implemente 1 agente de IA em produção em 6 meses. Não 10. **UM**. E meça resultado. 3. Treine a equipe em prompt engineering básico. 80% do ganho vem disso. 4. Reinvista parte do ganho de produtividade em inovação (produto, expansão, novos mercados). Não só em margem. 5. Cuidado com dependência de fornecedor único. Tenha pelo menos 2-3 fornecedores de modelo.

Se você é estudante / em início de carreira: 1. Aprenda a **usar IA**, não a programar IA (a não ser que vá ser engenheiro de IA). 2. Domine **uma área de aplicação** (marketing, vendas, direito, medicina, educação) + IA. A combinação é mais rara e valiosa que IA pura. 3. Construa projetos reais. Portfólio > diploma. 4. Aprenda o básico de **engenharia de prompt, RAG, agents**. São as habilidades que todo mundo vai precisar. 5. Não aposte em profissões que vão sumir. aposte em profissões que vão **mudar**.

Se você é líder / gestor: 1. Defina uma **política de uso de IA** na sua organização (segurança, dados, governança). 2. Crie um **comitê de IA** (ou pessoa) responsável por estratégia, avaliação e 采购. 3. Invista em **treinamento** de equipe. Toda a empresa, não só o time técnico. 4. Mensure **resultado de negócio** (não só "uso de IA"). Receita, margem,

NPS, velocidade. 5. Mantenha **human-in-the-loop** em decisões críticas. Sempre.

10. Riscos Reais no Horizonte 2031 e Como Mitigá-los

Os 7 riscos mais prováveis (e como mitigar)

1. Desemprego em massa em profissões cognitivas de rotina. -

Mitigação: requalificação massiva, renda básica universal (testes em vários países), políticas ativas de emprego.

2. Desinformação em escala industrial (deepfakes, fake news, manipulação). - Mitigação: regulação de proveniência (C2PA, watermarking), educação midiática, plataformas com responsabilidade legal.

3. Concentração de poder em poucas big techs. - Mitigação: antitrust forte, modelos open source fortes (Llama, Qwen, DeepSeek), interoperabilidade (MCP, APIs abertas).

4. Falhas catastróficas em sistemas críticos (saúde, energia, finanças, militar). - Mitigação: red-teaming, certificação, sandbox regulatório, human-in-the-loop, testes adversariais.

5. Corrida armamentista de IA (EUA-China, Israel-Irã, etc.). - Mitigação: diplomacia de IA, tratados internacionais (estilo Treaty on the Non-Proliferation of Nuclear Weapons).

6. Perda de privacidade e vigilância em massa. - Mitigação: criptografia homomórfica, computação confidencial, federated learning, regulamentação de dados (LGPD, GDPR).

7. Dependência cognitiva e atrofia de habilidades humanas. - Mitigação: educação que valorize pensamento crítico, criatividade, ética --- não só "usar IA". Preservar o humano que decide o que é valioso.

A linha de chegada: 2031

Em 2031, o mundo será **radicalmente diferente** de 2026. Mais produtivo, mais rico, mais saudável --- e mais desigual, mais complexo, mais perigoso. A escolha de como chegamos lá é **política, ética, educacional, regulatória** --- e, em última instância, **pessoal**. Cada profissional, cada empresa, cada governo, cada cidadão decide o papel que vai jogar nessa transição.

Nos próximos ebooks desta coletânea, vamos esticar o horizonte: 10 anos (2031-2036), 20 anos (2036-2046), 50 anos (2076), 100 anos (2126). As projeções vão ficando mais incertas, mas o método permanece o mesmo: **o que já existe, o que está em roadmap, o que a ciência projeta --- e o que pode dar errado.**

O Quinquênio Começa Agora!

Você acaba de ler a análise mais fundamentada que existe sobre o que vai mudar entre 2026 e 2031. Esse conhecimento é a sua bússola para os próximos 5 anos. Use-o. Construa. Adapte-se. Lidere. A próxima década vai ser a mais importante da história da humanidade --- e ela começa no momento em que você decidir o que fazer com o que acabou de aprender.

O que se esperar das IAs nos próximos 5 anos? --- Por MMN AI-to-AI

MMN AI-to-AI • 2026 • Todos os direitos reservados