

Capa

Claude: Skills Avançadas - Domine a Criação de Soluções Inteligentes e Personalizadas com IA

Construa Ferramentas Poderosas, Agentes Autônomos e Produtos de IA com Claude

Técnicas avançadas: tools, RAG, agents, fine-tuning e arquitetura de produção.

Por MMN AI-to-AI

MMN AI-to-AI • 2026

Sobre este ebook

Você já sabe usar Claude. Mas e construir produtos robustos em cima dele? E criar agentes que executam tarefas complexas autonomamente? E implementar sistemas de produção escaláveis? Este ebook é o mergulho técnico profundo que profissionais e empresas precisam. Vamos cobrir Skills (tools), RAG avançado, agentes, orquestração, fine-tuning, otimização de performance, deploy em produção, monitoramento e tudo mais. É um guia prático, com exemplos de código, padrões de arquitetura, armadilhas comuns e estratégias comprovadas. Ao final, você terá conhecimento para construir produtos de IA robustos, escaláveis e diferenciados com Claude.

Sumário

- 1. Tools e Skills: A API Completa
- 2. Skills Pré-Construídas e Customizadas
- 3. RAG Avançado com Claude
- 4. Agentes: O Estado da Arte
- 5. Claude Code: Programação Assistida por IA
- 6. Otimização de Custos e Performance
- 7. Deploy, Monitoramento e Observabilidade
- 8. Segurança e Guardrails
- 9. Casos Especiais e Limitações

- 10. Conclusão: Claude Como Plataforma de Inovação

1. Tools e Skills: A API Completa

Como funcionam as Tools

Tools são funções que Claude pode chamar. Você define: nome, descrição, parâmetros. Claude decide quando usar baseado na descrição. Você implementa a função. É o mecanismo fundamental de extensão do modelo.

Schema de uma Tool

Formato JSON Schema. Campos: name, description, input_schema. Boas descrições são cruciais --- é o que Claude lê para decidir. Exemplo: '\Busca produtos no e-commerce por categoria e faixa de preço\'.

2. Skills Pré-Construídas e Customizadas

Skills prontas para usar

Web search: Claude busca online. Code execution: roda Python. File reading: lê arquivos. PDF processing: processa PDFs. Computer Use: opera o computador. Skills disponíveis conforme evolução da plataforma.

Skills customizadas

Acesso a sua base de dados. Integração com CRM, ERP, sistema interno. Chamada a APIs de terceiros. Ações específicas do negócio. Com a API, você pode definir tools personalizadas ilimitadas.

3. RAG Avançado com Claude

Embeddings e bases vetoriais

Use Voyage AI (recomendado pela Anthropic) ou alternativas. Bases: Pinecone, Weaviate, Qdrant, Chroma, pgvector. Chunking: divida em pedaços semânticos de 500-1000 tokens. Overlap: preserve contexto entre chunks.

Técnicas avançadas

Hybrid search: combine vetorial + keyword. Re-ranking: refine com modelo mais simples. Query rewriting: Claude reformula a pergunta antes de buscar. Citation: peça Claude para indicar fontes. Multi-hop: busca iterativa para perguntas complexas.

4. Agentes: O Estado da Arte

Anatomia de um agente Claude

Modelo (Claude Sonnet/Opus). Tools (funções disponíveis). System prompt (instruções, personalidade, limites). Memória (curto e longo prazo). Loop de raciocínio. Guardrails (validações). Observabilidade. Frameworks: LangGraph, CrewAI, Claude Agent SDK.

Padrões de agentes

ReAct: loop thought-action-observation. Plan-and-Execute: planeja, executa. Reflexion: auto-critica. Multi-agent: vários agentes especializados. Hierarchical: gerente + trabalhadores. Human-in-the-loop: humano valida passos críticos. Cada padrão tem trade-offs.

5. Claude Code: Programação Assistida por IA

Funcionalidades

Editor inteligente no terminal. Lê, edita, cria arquivos. Executa comandos. Roda testes. Debugging automatizado. Refatoração inteligente. Suporte a qualquer linguagem. Integração com Git. É como ter um par programador sênior 24/7.

Workflows avançados

Code review automatizado. Geração de testes. Documentação. Migrations. Bug hunting. Prototipagem rápida. Aprendizado de novas linguagens. Refatoração em larga escala. Com Claude Code, programadores experimentam aumento de 3-5x em produtividade.

6. Otimização de Custos e Performance

Caching e prompt caching

Reuse contextos repetidos. Cache system prompts. Cache documentos grandes. Anthropic oferece prompt caching com redução de até 90% no custo. Fundamental para aplicações em escala.

Model routing e batching

Roteie tarefas simples para Haiku, complexas para Sonnet. Batch processing: agrupe tarefas. Streaming: UX melhor, custo similar. Compressão de prompts: prompts mais curtos. Otimização pode reduzir custos em 70-90%.

7. Deploy, Monitoramento e Observabilidade

Deploy em produção

API Anthropic diretamente. AWS Bedrock: integração AWS, VPC. Google Vertex AI: Google Cloud. Self-hosted enterprise: máximo controle. Use CDN, load balancer, retry logic, circuit breakers. Implemente de forma gradual (canary, blue-green).

Monitoramento essencial

Latência: p50, p95, p99. Custo: \\$/ request, \\$/ usuário. Taxa de erro. Taxa de hallucination (amostra). Satisfação do usuário. Tool failures. Use LangSmith, Helicone, Datadog, ou stack custom. Monitore constantemente.

8. Segurança e Guardrails

Defesas em camadas

Validação de input: filtre conteúdo perigoso. Validação de output: verifique respostas. Rate limiting. Detecção de anomalias. Auditoria de logs. Red team constante. Defense in depth: não dependa de uma única camada.

Compliance e auditoria

LGPD/GDPR: consentimento, direito ao esquecimento. HIPAA: BAA, criptografia. SOC2: controles, auditoria. EU AI Act: transparência, risco. Implemente políticas claras e auditoria regular. Claude facilita, mas responsabilidade é sua.

9. Casos Especiais e Limitações

Quando Claude tem dificuldades

Tarefas extremamente específicas de domínio (modelo especializado pode ser melhor). Cálculos matemáticos complexos (considere executar código). Tarefas em tempo real com latência crítica (Haiku, mas limites existem). Tarefas que exigem conhecimento pós-treinamento (use RAG).

Estratégias para contornar limitações

Decomposição: quebre em tarefas menores. RAG para conhecimento atual. Code execution para cálculos. Human-in-the-loop para decisões críticas. Multi-model: use Claude + outros. Conjugar técnicas é mais poderoso que depender de uma só.

10. Conclusão: Claude Como Plataforma de Inovação

O poder está nas suas mãos

Em 2026, qualquer desenvolvedor com conhecimento e criatividade pode construir produtos de IA que antes exigiriam equipes inteiras. Claude é a plataforma. Skills, agentes, RAG, Claude Code, tools --- todas as peças estão disponíveis. O que você constrói com elas depende da sua visão. Comece pequeno, experimente, construa em escala. O futuro está nas suas mãos.

Seu Império Começa Agora!

O conhecimento sem ação é apenas entretenimento. Você acaba de receber o mapa para dominar a inteligência artificial e multiplicar seus resultados. O próximo passo é seu: aplique as estratégias, construa suas soluções e assuma a liderança no seu mercado. A revolução não espera por ninguém. Vá e construa o seu futuro!

Skills Avançadas com Claude --- Por MMN AI-to-AI

MMN AI-to-AI • 2026 • Todos os direitos reservados